به نام خدا

آمار و کاربرد آن

فاز اول پروژه

پاییز ۱۴۰۵

ارشیا شهریاری

۴۰۲۱۱۰۶۴۹

۱ منشأ داده و سازوکار جمع‌آوری

مجموعه داده مورد استفاده در این پژوهش، برگرفته از پایگاه داده مرکز ملی هماهنگی آلزایمر ایالات متحده (NACC) است. این داده‌ها حاصل یک **مطالعه مشاهده‌ای و ارزیابی‌های بالینی** در مراکز تحقیقاتی بیماری آلزایمر (ADRCs) هستند. سازوکار تولید داده به صورت چندوجهی است و شامل دو بخش اصلی می‌باشد:

الف) داده‌های بالینی، شناختی و جمعیت‌شناختی که از طریق مصاحبه و آزمون‌های استاندارد (مجموعه داده یکنواخت یا UDS جمع‌آوری شده‌اند (فایل udslong_imputed.csv).

ب) داده‌های تصویربرداری تشدید مغناطیسی (MRI) که ساختار و حجم نواحی مختلف مغز را اندازه‌گیری کرده‌اند (فایل mriscanclean.csv).

از نظر محدودیت دسترسی، داده‌های اصلی NACC نیازمند ثبت‌نام و تاییدیه پژوهشی هستند، اما برای این پروژه، یک زیرمجموعه پاک‌سازی شده و از پیش آماده در اختیار قرار گرفته است.

۲ واحد مشاهده و ساختار داده

در زیرمجموعه فعلی، **واحد مشاهده یک «بیمار/شرکت‌کننده مستقل» در یک نوبت ویزیت** است. با ادغام دو فایل UDS و MRI بر اساس شناسه یکتای هر فرد ،(NACCID) ساختار سلسله‌مراتبی و مراجعات تکراری حذف شده است؛ به طوری که برای هر فرد دقیقاً یک ردیف داده وجود دارد (تناظر یک‌به‌یک). جدول زیر ساختار ساده‌شده این ادغام را نشان می‌دهد:

شناسه بیمار (NACCID)	سابقه خانوادگی (NACCFAM)	نمره شناخت (MOCATOTS)	حجم هیپوکامپ چپ (LH_HIPPOCAMPUS_GVOL)
NACC1001	۱	۲۴	۵.۳۱۲۰
NACC1002	۰	۲۸	۱.۳۴۵۰
NACC1003	۱	۱۵	۸.۲۴۱۰

جدول ۱: نمایی ساده از ساختارداده‌ها (یک ردیف به ازای هر شرکت‌کننده)

۳ نمونه‌گیری، انتخاب و قابلیت تعمیم

نمونه‌گیری در این پایگاه داده **تصادفی نیست**، بلکه از نوع نمونه‌گیری در دسترس و مبتنی بر مراجعات بالینی است. افراد حاضر در این مجموعه، بیمارانی هستند که توسط پزشک ارجاع داده شده‌اند یا داوطلبانه برای غربالگری و ارزیابی اختلالات شناختی به مراکز تخصصی مراجعه کرده‌اند. بنابراین، این یک **مطالعه مشاهده‌ای** است و نتایج آن را **نمی‌توان به کل جامعه عمومی تعمیم داد**. قابلیت تفسیر و تعمیم نتایج صرفاً محدود به «بزرگسالان و سالمندانی است که دارای دغدغه‌های شناختی بوده یا برای پیگیری عوامل خطر زوال عقل تحت مراقبت‌های بالینی تخصصی قرار دارند».

۴ طبقه‌بندی متغیرها

بر اساس سؤال آماری پروژه (پیش‌بینی افت نمرات ارزیابی شناختی از روی میانگین ضخامت قشر مغز در بیماران دچار اختلال شناختی)، متغیرهای اصلی مطالعه به شرح جدول زیر طبقه‌بندی می‌شوند:

نام متغیر	منبع داده	نقش در پژوهش	نوع و مقیاس اندازه‌گیری
LH/RH_ENTORHINAL_AVGTH	MRI	توضیحی (پیش‌بینی‌کننده)	کمی پیوسته (میلی‌متر)
LH/RH_PRECUNEUS_AVGTH	MRI	توضیحی (پیش‌بینی‌کننده)	کمی پیوسته (میلی‌متر)
LH_ENTORHINAL_GVOL	MRI	توضیحی	کمی پیوسته (میلی‌متر مکعب)
MOCATOTS	UDS	پاسخ	کمی گسسته (بازه ۰ تا ۳۰)
VEG / ANIMALS	UDS	پاسخ	کمی گسسته (تعداد در ۶۰ ثانیه)
TRAILB / TRAILA	UDS	پاسخ	کمی پیوسته (ثانیه)
NACCUDSD	UDS/MRI	گروه‌بندی و فیلتر جامعه هدف	کیفی ترتیبی (کدهای ۱ تا ۴)
NACCAGE	UDS	کنترلی	کمی پیوسته (سال)
EDUC	UDS	کنترلی	کمی گسسته (سال‌های تحصیل)
SEX	UDS	کنترلی	کیفی اسمی دودویی (۱=مرد، ۲=زن)
NACCID	UDS/MRI	کلید اتصال داده‌ها	کیفی اسمی (شناسه یکتا)

جدول ۲: طبقه‌بندی متغیرهای اصلی پژوهش، نقش آماری و مقیاس اندازه‌گیری آن‌ها

۵ ممیزی کیفیت داده و مدیریت مقادیر گمشده

بررسی اولیه نشان می‌دهد که در فایل‌های خام،هیچ رکورد تکراری بر اساس NACCID ثبت نشده است. با این حال، در استاندارد NACC، عدم انجام آزمون یا نامشخص بودن وضعیت با کدهای عددی خاص (خارج از دامنه مجاز) ثبت می‌شود و در فایل udslong_imputed.csv نیز برخی از این کدها طی فرآیند ایمپیوتیشن اولیه به اعداد اعشاری خارج از سقف مجاز تبدیل شده‌اند. قواعد ممیزی و پاک‌سازی اعمال‌شده به شرح زیر است:

- **سال‌های تحصیل (EDUC):** مقادیر بالای ۳۶ سال (کد ۹۹ به معنای نامشخص) شامل ۲ مورد در کل داده (۰٫۱۶ درصد) به NaN تبدیل شد.
- **نمره آزمون مونترال (MOCATOTS):** دامنه مجاز ۰ تا ۳۰ است. مقادیر بالای ۳۰ (شامل کد ۸۸ به معنای انجام‌نشده و مقادیر ایمپیوت‌شده بالای ۳۰) شامل ۹ مورد در کل داده (۰٫۷۳ درصد) و ۴ مورد در گروه بیماران (۱٫۰۴ درصد) به NaN تبدیل شد.
- **آزمون‌های روانی کلامی (VEG ANIMALS):** کدهای ۹۵ تا ۹۸ نشان‌دهنده عدم انجام تست به دلایل فیزیکی، شناختی یا امتناع هستند. این موارد (۱۱ مورد در ANIMALS و ۱۴ مورد در VEG در کل داده؛ ۷ و ۱۰ مورد در گروه بیماران) به NaN تغییر یافتند.
- **آزمون خط‌کشی مسیر A و B (TRAILA TRAILB):** سقف زمانی استاندارد برای TRAILA برابر ۱۵۰ ثانیه و برای TRAILB برابر ۳۰۰ ثانیه است و کدهای ۹۹۵ تا ۹۹۸ بیانگر ناتوانی در تکمیل آزمون هستند. در کل داده، ۲۶ مورد (۱۰.۲ درصد) در TRAILA و ۶۴ مورد (۱۷.۵ درصد) در TRAILB خارج از سقف مجاز بودند. نکته بسیار مهم بالینی آن است که از ۶۴ مورد گمشده TRAILB، تعداد **۵۸ مورد (۱۴.۱۵ درصد از گروه بیماران)** متعلق به مبتلایان به MCI و دمانس است که به علت دشواری شناختی آزمون قادر به اتمام آن نبوده‌اند.
- **متغیرهای MRI:** تمامی متغیرهای ضخامت قشر مغز (AVGTH) در هر ۱۲۳۷ نفر کامل و در بازه زیستی معتبر (بین ۷۳.۰ تا ۹۸.۳ میلی‌متر) قرار دارند. تنها در متغیر حجم ماده خاکستری LH_ENTORHINAL_GVOL یک مقدار صفر در گروه سالم مشاهده شد که به NaN تبدیل گردید.
- **تصمیم تحلیلی:** به جای حذف کامل سطر بیمارانی که تنها یک آزمون دشوار (مانند TRAILB) را انجام نداده‌اند، مقادیر نامعتبر به NaN تبدیل شدند تا در تحلیل هر آزمون، تمام مشاهدات معتبر آن آزمون حفظ شوند (حفظ ۳۸۳ بیمار مبتلا به MCI و دمانس).

۶ جدول‌های فراوانی و توزیع تجربی متغیرهای طبقه‌ای

جدول زیر توزیع فراوانی و درصد وضعیت تشخیص شناختی (NACCUDSD) و جنسیت (SEX) را در کل مجموعه داده ($N = ۱۲۳۷$) و در زیرمجموعه تحلیلی بیماران دچار اختلال شناختی ($N = ۳۸۳$) نشان می‌دهد:

متغیر طبقه‌ای	سطح / کد	فراوانی در کل داده	درصد در کل داده	فراوانی (درصد) در گروه هدف ($N = ۳۸۳$)
وضعیت شناختی (NACCUDSD)	۱: شناخت سالم (Normal)	۸۴۷	۶۸٫۴۷٪	— (خارج از جامعه هدف)
	۲: اختلال بدون MCI	۷	۰٫۵۷٪	— (خارج از جامعه هدف)
	۳: اختلال شناختی خفیف (MCI)	۲۵۲	۲۰٫۳۷٪	۲۵۲ (۶۵٫۸۰٪)
	۴: دمانس / زوال عقل (Dementia)	۱۳۱	۱۰٫۵۹٪	۱۳۱ (۳۴٫۲۰٪)
جنسیت (SEX)	۱: مرد (Male)	۴۹۷	۴۰٫۱۸٪	۱۹۱ (۴۹٫۸۷٪)
	۲: زن (Female)	۷۴۰	۵۹٫۸۲٪	۱۹۲ (۵۰٫۱۳٪)

جدول ۳: جدول فراوانی و درصد متغیرهای طبقه‌ای در کل نمونه و زیرگروه بیماران دچار اختلال شناختی

الگوی مهم مشاهده‌شده: در کل مجموعه داده، اکثریت افراد (۶۸٫۴۷ درصد) دارای شناخت سالم هستند و زنان حدود ۶۰ درصد نمونه را تشکیل می‌دهند. اما هنگامی که جامعه هدف را به بیماران دارای اختلال شناختی (MCI و دمانس، $N = ۳۸۳$) محدود می‌کنیم، تقریباً دو-سوم بیماران (۶۵٫۸۰ درصد) در مرحله MCI و یک-سوم (۳۴٫۲۰ درصد) در مرحله دمانس قرار دارند و توزیع جنسیتی کاملاً متوازن (۴۹٫۸۷ درصد مرد و ۵۰٫۱۳ درصد زن) می‌شود.

۷ معیارهای مرکز و پراکندگی متغیرهای کمی

جدول زیر خلاصه آماره‌های مرکزی و پراکندگی متغیرهای کمی را در جامعه هدف پژوهش (بیماران MCI و دمانس، $N = ۳۸۳$) نشان می‌دهد:

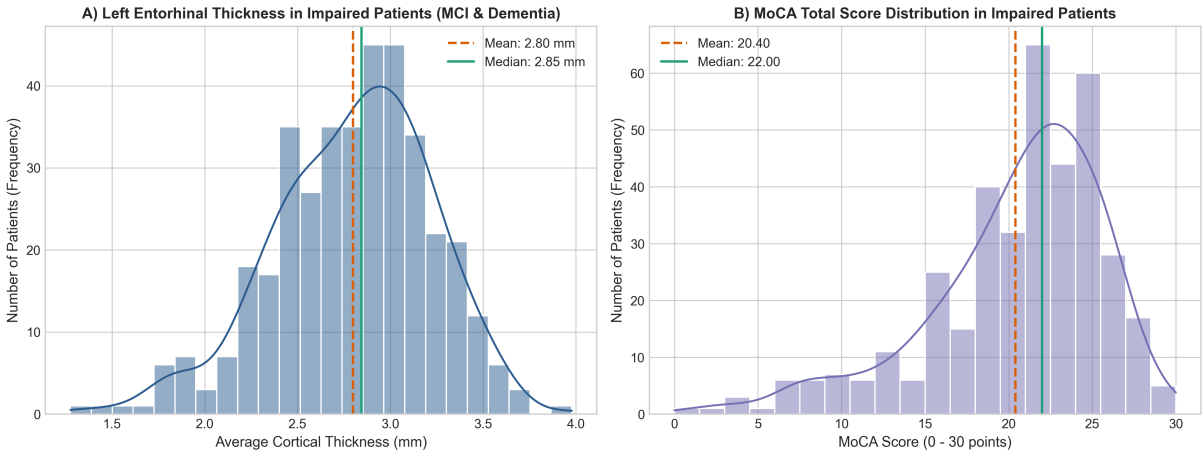
متغیر	تعداد معتبر	گمشده	میانگین	انحراف معیار	میانه	چارک اول	چارک سوم	IQR	بازه (کمینه–بیشینه)
NACCAGE (سال)	۳۸۳	۰	۷۰٫۲۱	۸٫۰۱	۷۱٫۰۰	۶۵٫۰۰	۷۶٫۰۰	۱۱٫۰۰	۴۵٫۰۰ – ۹۱٫۰۰
EDUC (سال)	۳۸۲	۱	۱۵٫۹۷	۲٫۹۴	۱۶٫۰۰	۱۴٫۰۰	۱۸٫۰۰	۴٫۰۰	۰٫۰۰ – ۲۰٫۰۰
MOCATOTS	۳۷۹	۴	۲۰٫۴۰	۵٫۲۸	۲۲٫۰۰	۱۸٫۰۰	۲۴٫۰۰	۶٫۰۰	۰٫۰۰ – ۳۰٫۰۰
ANIMALS	۳۷۶	۷	۱۵٫۹۸	۶٫۰۶	۱۶٫۰۰	۱۲٫۰۰	۱۹٫۲۵	۷٫۲۵	۱٫۰۰ – ۳۵٫۰۰
VEG	۳۷۳	۱۰	۱۰٫۱۷	۴٫۱۰	۱۰٫۰۰	۷٫۰۰	۱۳٫۰۰	۶٫۰۰	۰٫۰۰ – ۲۵٫۰۰
TRAILA (ثانیه)	۳۶۲	۲۱	۴۶٫۹۹	۲۹٫۹۲	۳۸٫۰۰	۲۹٫۰۰	۵۲٫۰۰	۲۳٫۰۰	۱۱٫۰۰ – ۱۵۰٫۰۰
TRAILB (ثانیه)	۳۲۵	۵۸	۱۳۸٫۵۸	۸۰٫۷۷	۱۰۹٫۰۰	۷۸٫۰۰	۱۶۳٫۰۰	۸۵٫۰۰	۳۳٫۰۰ – ۳۰۰٫۰۰
LH_ENTORHINAL_AVGTH	۳۸۳	۰	۲٫۸۰	۰٫۴۳	۲٫۸۴	۲٫۵۱	۳٫۱۰	۰٫۵۹	۱٫۲۸ – ۳٫۹۸
RH_ENTORHINAL_AVGTH	۳۸۳	۰	۲٫۸۹	۰٫۴۷	۲٫۹۳	۲٫۶۳	۳٫۲۰	۰٫۵۷	۰٫۷۳ – ۳٫۸۷
LH_PRECUNEUS_AVGTH	۳۸۳	۰	۲٫۲۳	۰٫۲۰	۲٫۲۴	۲٫۱۵	۲٫۳۵	۰٫۲۰	۰٫۷۳ – ۳٫۱۷
LH_ENTORHINAL_GVOL	۳۸۳	۰	۱۴۶۲٫۳۰	۴۸۶٫۸۸	۱۴۰۷٫۰۰	۱۱۲۴٫۰۰	۱۷۲۸٫۵۰	۶۰۴٫۵۰	۲۱۱٫۰ – ۴۲۶۵٫۰

جدول ۴: آماره‌های مرکز و پراکندگی متغیرهای کمی در زیرگروه بیماران مبتلا به اختلال شناختی ($N = ۳۸۳$)

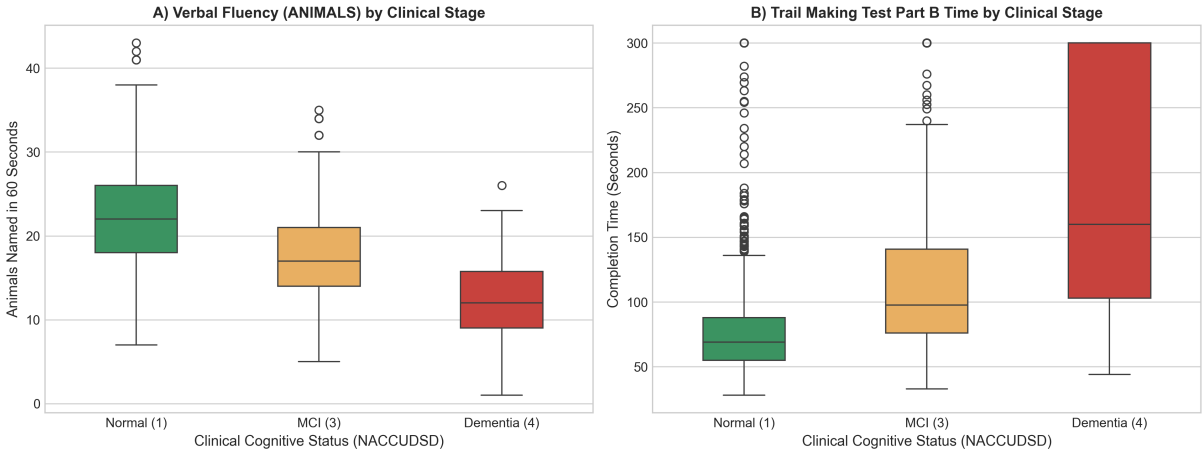
تفسیر تناسب معیارها: برای متغیرهایی مانند ضخامت قشر مغز (LH_ENTORHINAL_AVGTH) و آزمون روانی کلامی (ANIMALS) که توزیع نسبتاً متقارنی دارند، میانگین و میانه بسیار به یکدیگر نزدیک هستند (به ترتیب ۲٫۸۰ در برابر ۲٫۸۴ میلی‌متر، و ۱۵٫۹۸ در برابر ۱۶٫۰۰ کلمه)؛ بنابراین میانگین و انحراف معیار معیارهای مناسبی هستند. در مقابل، برای زمان آزمون خط‌کشی (TRAILA و TRAILB) که دارای چولگی شدید به راست هستند (میانگین TRAILB برابر ۱۳۸٫۵۸ ثانیه اما میانه آن ۱۰۹ ثانیه است) و همچنین نمره MOCATOTS که در بیماران دمانس دارای چولگی به چپ است، **میانه و دامنه بین‌چارکی (IQR)** شاخص‌های مقاوم‌تر و دقیق‌تری نسبت به میانگین محسوب می‌شوند.

۸ مصورسازی داده‌ها

در ادامه، چهار نمودار استاندارد و متناسب با نوع متغیرها جهت بررسی توزیع‌ها و روابط اولیه ارائه شده است:



شکل ۱: هیستوگرام و تخمین برای ضخامت قشر انتورینال چپ (الف) و نمره کل MoCA (ب) در بیماران دچار اختلال شناختی.



شکل ۲: نمودارهای جعبه‌ای مقایسه نمره روانی کلامی ANIMALS (الف) و زمان آزمون TRAILB (ب) در سه گروه سالم، MCI و دمانس.

۹ مقایسه توصیفی اولیه بین گروه‌ها

جدول زیر مقایسه توصیفی متغیرهای تصویربرداری و شناختی را میان سه گروه اصلی تشخیصی (سالم، MCI و دمانس) نشان می‌دهد:

متغیر	سالم (Normal، $N = ۸۴۷$)		اختلال خفیف (MCI، $N = ۲۵۲$)		دمانس (Dementia، $N = ۱۳۱$)	
	میانگین (SD)	میانه (IQR)	میانگین (SD)	میانه (IQR)	میانگین (SD)	میانه (IQR)
(mm) LH_ENTORHINAL_AVGTH	۳٫۰۵ (۰٫۳۴)	۳٫۰۷ (۰٫۴۰)	۲٫۸۶ (۰٫۴۳)	۲٫۹۲ (۰٫۵۷)	۲٫۶۷ (۰٫۳۹)	۲٫۶۷ (۰٫۵۲)
(mm) RH_ENTORHINAL_AVGTH	۳٫۱۳ (۰٫۳۴)	۳٫۱۵ (۰٫۴۲)	۲٫۹۵ (۰٫۴۹)	۳٫۰۱ (۰٫۵۱)	۲٫۷۶ (۰٫۴۱)	۲٫۷۵ (۰٫۶۰)
(mm) LH_PRECUNEUS_AVGTH	۲٫۳۲ (۰٫۱۱)	۲٫۳۳ (۰٫۱۵)	۲٫۲۵ (۰٫۲۰)	۲٫۲۷ (۰٫۱۹)	۲٫۱۷ (۰٫۱۹)	۲٫۱۹ (۰٫۲۶)
(۳۰–۰) MOCATOTS	۲۶٫۱۷ (۲٫۳۶)	۲۶٫۲۰ (۳٫۰۰)	۲۲٫۴۰ (۳٫۳۸)	۲۳٫۰۰ (۵٫۰۰)	۱۶٫۴۸ (۶٫۱۰)	۱۷٫۰۰ (۸٫۰۰)
(تعداد) ANIMALS	۲۲٫۳۲ (۵٫۴۳)	۲۲٫۰۰ (۸٫۰۰)	۱۷٫۸۵ (۵٫۵۶)	۱۷٫۰۰ (۷٫۰۰)	۱۲٫۲۷ (۵٫۲۶)	۱۲٫۰۰ (۶٫۷۵)
(ثانیه) TRAILA	۳۰٫۶۵ (۱۱٫۷۹)	۲۹٫۰۰ (۱۲٫۰۰)	۳۸٫۶۶ (۱۷٫۰۳)	۳۵٫۵۰ (۱۷٫۰۰)	۶۵٫۱۳ (۴۱٫۷۳)	۴۷٫۵۰ (۵۱٫۰۰)
(ثانیه) TRAILB	۷۸٫۶۱ (۴۰٫۷۲)	۶۹٫۰۰ (۳۳٫۰۰)	۱۲۰٫۱۷ (۶۶٫۰۲)	۹۷٫۵۰ (۶۴٫۷۵)	۱۸۸٫۹۲ (۹۵٫۲۰)	۱۶۰٫۰۰ (۱۹۷٫۰۰)

جدول ۵: مقایسه توصیفی شاخص‌های ضخامت قشر مغز و نمرات شناختی در سه مرحله بالینی

از دیدگاه توصیفی ، یک روند یکنواخت و هم‌جهت مشاهده می‌شود: با حرکت از وضعیت شناخت سالم به سمت MCI و سپس دمانس، میانگین ضخامت قشر انتورینال چپ از ۳٫۰۵ به ۲٫۸۶ و سپس ۲٫۶۷ میلی‌متر کاهش می‌یابد و هم‌زمان میانه نمره MOCATOTS از ۲۶٫۲۰ به ۲۳٫۰۰ و ۱۷٫۰۰ سقوط کرده و میانه زمان TRAILB از ۶۹ ثانیه به ۹۷٫۵ و ۱۶۰ ثانیه افزایش می‌یابد.

۱۰ نهایی کردن سؤال آماری

با توجه به شناخت حاصل از ممیزی داده و کامل بودن متغیرهای ضخامت قشر مغز و نمره MOCATOTS (تنها ۱٫۰۴ درصد گمشدگی در گروه هدف در برابر ۱۵٫۱۴ درصد گمشدگی در TRAILB)، سؤال اصلی پژوهش به صورت زیر نهایی و دقیق‌تر می‌شود:

> **سؤال نهایی:** «در بیماران مبتلا به اختلال شناختی خفیف (MCI) و دمانس ، کاهش میانگین ضخامت قشر مغز در نواحی کلیدی آلزایمر تا چه حد با افت نمره ارزیابی شناختی مونترال (MOCATOTS) و نمره روانی کلامی مرتبط است و پس از کنترل سن و تحصیلات چه میزان از واریانس این نمرات را تبیین می‌کند؟»

۱۱ الزامات ویژه مسیر ج

۱.۱۱ ج ۱. نقشه زیرمجموعه UDS و MRI

مجموعه داده تحویلی شامل دو فایل است:

۱. **فایل udslong_imputed.csv (۱۲۳۷ سطر و ۱۸۰ ستون):** دربرگیرنده متغیرهای جمعیت‌شناختی (SEX, NACCAGE, EDUC, RACE)، سوابق پزشکی و قلبی-عروقی (CVHATT, DIABETES, HYPERTEN)، مقیاس‌های روان‌پزشکی و افسردگی (NPI-Q, NACCGDS)، فعالیت‌های عملکردی روزمره (FAQ: BILLS, TAXES, ...)، آزمون‌های عصب‌روان‌شناختی (MOCATOTS, ANIMALS, VEG, TRAILA, TRAILB) و تشخیص بالینی (NACCUDSD, CDRSUM, CDRGLOB).

۲. **فایل mriscanclean.csv (۱۲۳۷ سطر و ۱۲۶ ستون):** شامل شناسه NACCID، متغیر تشخیصی NACCUDSD و ۱۲۴ متغیر مورفومتریک استخراج‌شده از تصاویر T1-weighted MRI برای ۳۱ ناحیه قشری در هر دو نیمکره چپ (LH) و راست (RH) بر اساس اطلس Desikan-Killiany. برای هر ناحیه دو ویژگی ثبت شده است: حجم ماده خاکستری بر حسب میلی‌متر مکعب (GVOL) و میانگین ضخامت قشر مغز بر حسب میلی‌متر (AVGTH).

۲.۱۱ ج ۲. ساختار شرکت‌کننده و مراجعه

بررسی کلید NACCID با تابع duplicated().any() نشان داد که در هر دو فایل UDS و MRI، تعداد شرکت‌کنندگان یکتا دقیقاً ۱۲۳۷ نفر است و هیچ شرکت‌کننده‌ای بیش از یک مراجعه در این زیرمجموعه ندارد (توزیع تعداد مراجعه به ازای هر فرد: ۱۰۰ درصد دقیقاً ۱ مراجعه). بنابراین، هر سطر از پیش نماینده یک مراجعه شاخص (Index Visit) مستقل برای یک بیمار یکتاست و شرط استقلال مشاهدات برای فازهای استنباطی و رگرسیونی کاملاً برقرار است.

۳.۱۱ ج ۳. اتصال UDS و MRI

اتصال دو جدول بر اساس کلید مشترک NACCID به روش Inner Join انجام شد. جدول جریان داده (Data Flow) زیر خلاصه این اتصال و فیلتر شدن به جامعه هدف را نشان می‌دهد:

مرحله پردازش و اتصال داده	تعداد شرکت‌کنندگان یکتا
تعداد افراد در فایل بالینی (udslong_imputed.csv)	۱۲۳۷
تعداد افراد در فایل تصویربرداری (mriscanclean.csv)	۱۲۳۷
تعداد افراد مشترک پس از اتصال UDS + MRI (موارد بدون تطابق: ۰)	۱۲۳۷
حجم نمونه زیرگروه تحلیلی اصلی (مبتلایان به MCI کد ۳ و دمانس کد ۴)	۳۸۳
حجم نمونه دارای هر دو وجه کامل برای تحلیل اصلی (MOCATOTS و AVGTH معتبر)	۳۷۹

جدول ۶: جدول جریان اتصال داده‌های UDS و MRI و تعریف نمونه تحلیلی چندوجهی

۴.۱۱ ج ۴. داده‌های گمشده و انتخاب شدن نمونه چندوجهی

این سوال در قسمت پنج پاسخ داده شده است.

۵.۱۱ ج ۵. خلاصه مشترک شناختی و تصویربرداری

این سوال در قسمت‌های قبل پاسخ داده شده است.